

Thema 2 · Verdelingen bekijken

Deel 1 — Beschrijven · *het spelletje*

Inhoudsopgave

Van één gok naar de hele groep	1
De frequentietabel	2
Centrum: modus, mediaan, gemiddelde	3
De mediaan in twee stappen	4
Spreiding: kwartielen, IQR en de boxplot	5
Uitbijters: de 1,5-IQR-regel	6
Scheefheid	7
Spreiding terugrekenen uit een frequentietabel	8
Oefenen	8
Tot slot	11

Van één gok naar de hele groep

In thema 1 deden we één gok: er kwam een egel binnen, en onze beste schatting was het gemiddelde. Maar één getal — het gemiddelde — verbergt veel. Liggen de egels netjes rond de 20 cm, of zit er een groep kleintjes en een groep groten? Is er eentje die er compleet uitspringt?

Daarvoor moet je naar de **hele verdeling** kijken: hoe de waarnemingen verspreid liggen. Dat is dit thema. Geen nieuwe gok, wel een beter beeld.

De egels, nog steeds

We houden ons doorlopende groepje (lengtes in cm):

11, 14, 17, 20, 20, 20, 23, 26, 29

Negen egels, gemiddelde 20 cm. Nu bekijken we niet hun gemiddelde, maar hun verdeling.

Wat is hier eigenlijk ‘verdeeld’?

Een eerlijke vraag waar bijna niemand bij stilstaat. We zeggen “de **verdeling** van de egels” — maar wat verdelen we nou over wat? De egels over de lengtes, of de lengtes over de egels? Verdeel je pizza’s over mensen, of mensen over pizza’s — en maakt het uit?

Het antwoord: **we verdelen wél degelijk — letterlijk**. We leggen de negen egels neer langs een lengte-as: de één bij 11, de ander bij 29. Wat verdeeld wordt is gewoon aanwijsbaar — wijs het ook áán: *de egels*, niet “de data” of “het”. Het punt is alleen dat ze er **niet eerlijk** liggen: niet allemaal op één hoopje bij 20. En juist die oneerlijkheid — dat ze uit elkaar liggen — is de verdeling. Lagen ze allemaal op precies 20, dan viel er niks te bekijken. Geen verschil, geen verdeling, geen verhaal.

De frequentietabel


Als waarden zich herhalen, is een lijst onhandig. Een **frequentietabel** telt hoe vaak elke waarde voorkomt. Een uil vangt ’s nachts muizen; over 20 nachten turven we de vangst:

i	aantal muizen x_i	f_i	%	$\sum f_i$	cum. %
1	0	2	10 %	2	10 %
2	1	5	25 %	7	35 %
3	2	7	35 %	14	70 %
4	3	4	20 %	18	90 %
5	4	2	10 %	20	100 %
		20	100 %		

Lees de kolommen:

- **Frequentie** f — hoe vaak een waarde voorkomt (7 nachten ving de uil precies 2 muizen).
- **Percentage** — f gedeeld door het totaal, maal 100 (denk liever in **proporties**: $7/20 = 0,35$; een proportie loopt van 0 tot 1, een percentage van 0 tot 100).
- **Cumulatief** — alles tot en met die rij opgeteld. Op 70 % van de nachten ving de uil twee muizen of minder. Anders gezegd: pak je willekeurig één van de twintig nachten, dan is de kans dat de uil **hooguit twee** muizen ving 0,70. Zo wordt “cumulatief” meteen een **kans** — precies het sommetje dat we vanaf het volgende thema steeds maken.

Diezelfde tabel zie je in één oogopslag als je de frequenties als staafjes tekent — de hoogte is hoe vaak een waarde voorkomt:



Figuur 1: Frequentieverdeling van de uilenvangst over 20 nachten: aantal muizen per nacht (horizontaal) tegen het aantal nachten dat dit voorkwam (verticaal). Dit is de frequentietabel als plaatje — de hoogste staaf (2 muizen, 7 nachten) is meteen de modus.

Centrum: modus, mediaan, gemiddelde

Drie manieren om “het midden” te vangen.

- **Modus** — de waarde die het vaakst voorkomt. Bij de uil: **2 muizen** ($f = 7$). Snel,

maar zwak als “midden” — al is hij bij **categorische** data (kleur, soort) juist de enige zinnige centrummaat.

- **Mediaan** — de middelste waarde. Robuust: hij trekt zich niets aan van uitschieters.
- **Gemiddelde** — de balanspunt-gok uit thema 1. Gevoelig: één extreme waarde sleurt hem mee.

De mediaan in twee stappen

Bepaal de mediaan altijd in twee vragen: **waar** zit hij, en **wat** is hij.

1. **Waar?** Het rangnummer van de mediaan is $\frac{n+1}{2}$. Voor de egels: $\frac{9+1}{2} = 5$ — de vijfde egel op volgorde.
2. **Wat?** De vijfde egel (gesorteerd) meet **20 cm**. Mediaan = 20.

Bij een even aantal valt het rangnummer tussen twee egels in; dan neem je hun gemiddelde. Bijvoorbeeld bij zes egels (11, 14, 17, 20, 23, 26) is er geen middelste — de mediaan wordt $(17 + 20)/2 = 18,5$.

Positie en waarde zijn twee dingen

Een kwantiel vind je altijd in twee stappen: eerst het **rangnummer** (de *positie* in de geordende rij), dan de **waarde** op die positie. Het rangnummer zegt *waar* je moet kijken — niet *wat* eruit komt.

Maat	Positie (rangnummer)
Q_1	$\frac{n+1}{4}$
Mediaan (Q_2)	$\frac{n+1}{2}$
Q_3	$\frac{3(n+1)}{4}$

Valt een rangnummer tussen twee waarnemingen in (bijvoorbeeld 2,5), dan neem je het gemiddelde van de twee burens. Merk op: de positie hangt **alleen van** n af — niet van hóé groot of klein de waarden zijn.

Waarom de mediaan robuust is

Stel je meet de huizenprijzen in een straat waar toevallig de koning woont. Dat ene paleis trekt het *gemiddelde* omhoog tot iets wat niemand herkent. De *mediaan* — het

middelste huis — verandert er nauwelijks van. Bij scheve verdelingen of uitschieters is de mediaan vaak het eerlijker midden.

Spreiding: kwartielen, IQR en de boxplot

De mediaan deelt de groep in twee helften. Deel elke helft nóg eens, en je hebt **kwartielen**.

- Q_1 (eerste kwartiel) = de mediaan van de onderste helft. Rangnummer $\frac{n+1}{4} = 2,5$
→ tussen de 2e (14) en 3e (17) egel → $Q_1 = 15,5$.
- Q_2 = de gewone mediaan = 20.
- Q_3 (derde kwartiel) = de mediaan van de bovenste helft. Rangnummer $\frac{3(n+1)}{4} = 7,5$
→ tussen de 7e (23) en 8e (26) → $Q_3 = 24,5$.

De **interkwartielafstand** vangt de spreiding van de middelste 50 %:


$$\text{IQR} = Q_3 - Q_1 = 24,5 - 15,5 = 9 \text{ cm}$$

Samen met het kleinste en grootste getal heb je de **five-number summary**, en die teken je als **boxplot**:

$$\underbrace{11}_{\min(Q_0)} \quad \underbrace{15,5}_{Q_1} \quad \underbrace{20}_{\text{mediaan}(Q_2)} \quad \underbrace{24,5}_{Q_3} \quad \underbrace{29}_{\max(Q_4)}$$

De box loopt van Q_1 tot Q_3 (de middelste 50 %), met een streep op de mediaan; de “snorharen” lopen naar het kleinste en grootste getal binnen bereik.

Soms is het handig om het zo te zien: het minimum is eigenlijk Q_0 en het maximum Q_4 — de “nulde” en “vierde” kwartielgrens. Dan staat de five-number summary er als één nette reeks Q_0, Q_1, Q_2, Q_3, Q_4 : van helemaal onderaan, in stappen van 25 %, naar helemaal bovenaan.



Figuur 2: Boxplot van de negen egels, opgebouwd uit de five-number summary die we met de hand vonden. De box (lichtblauw) loopt van $Q_1 = 15,5$ tot $Q_3 = 24,5$; de streep erin is de mediaan (20); de snorharen reiken naar het kleinste (11) en grootste (29) getal. De verdeling is symmetrisch: de mediaan ligt midden in de box en beide snorharen zijn even lang.

Uitbijters: de 1,5·IQR-regel

Wanneer is een waarneming een echte uitschieter? De vuistregel: alles méér dan $1,5 \times \text{IQR}$ voorbij een kwartiel.


Neem elf eksters en hun verzameling glimmertjes:

12, 13, 14, 14, 15, 16, 17, 18, 19, 20, 40

Hier is $Q_1 = 14$, $Q_3 = 19$, dus $\text{IQR} = 5$ en $1,5 \times \text{IQR} = 7,5$.

- Bovengrens: $Q_3 + 7,5 = 26,5$.
- De hoarder-ekster met **40** ligt daar ver boven → **uitbijter** (in de boxplot een los sterretje). De snorhaar stopt bij 20, de laatste waarde binnen de grens.

Let op: een uitbijter is dus niet “een grote waarde”, maar een waarde **buiten** de grenzen — onder $Q_1 - 1,5 \cdot \text{IQR}$ óf boven $Q_3 + 1,5 \cdot \text{IQR}$. De ondergrens ligt hier op $14 - 7,5 = 6,5$; geen enkele ekster zit daaronder, dus aan de onderkant is er niets aan de hand.



Figuur 3: Boxplot van de elf eksters. De stippellijn markeert de grens $Q_3 + 1,5 \times IQR = 26,5$. De snorhaar stopt op 20 — de laatste waarde binnen de grens — en de hoarder met 40 verschijnt als los sterretje erbuiten: een uitbijter. Vergelijk met de egels: hier zit de mediaan níét in het midden van de box, een teken van scheefheid.

Scheefheid

Vergelijk mediaan en gemiddelde, dan weet je meteen de vorm:

- **Symmetrisch** — gemiddelde $\approx$ mediaan (zoals de egels: beide 20).
- **Rechts-scheef** — een staart naar rechts (de eksters met die ene hoarder); het gemiddelde wordt naar rechts getrokken, dus **gemiddelde > mediaan**.
- **Links-scheef** — spiegelbeeld: **gemiddelde < mediaan**.

Het beeld eronder is steeds hetzelfde: **het gemiddelde laat zich naar de staart toe trekken, de mediaan blijft zitten**. Eén uitschieter sleept het gemiddelde mee — denk aan de koning in de straat — terwijl de mediaan alleen naar posities kijkt en nauwelijks verschuift. Hoe verder gemiddelde en mediaan uit elkaar liggen, hoe schever de verdeling, en de kant waar het gemiddelde naartoe is getrokken wijst de staart aan.

Verder kijken (niet verplicht): QQ-plot, stem-leaf, normaliteitstoets

- **Stam-en-blad-diagram** — de tientallen vormen de stam, het laatste cijfer een blad. Kantel je het, dan zie je een histogram: handig voor scheefheid.
- **QQ-plot** — zet je waargenomen z -scores af tegen wat je onder een normaalverdeling zou verwachten. Liggen de punten op de lijn, dan oogt het normaal; buigen de uiteinden weg, dan is het scheef.

- **Normaliteitstoets (Kolmogorov-Smirnov)** — let op de titel: “*test of normality*” toetst de H_0 dat de data normaal verdeeld is in de populatie. $p > .05 \rightarrow H_0$ niet verwerpen $\rightarrow$ je *má*g normaliteit aannemen. (Toetsen komt in deel 5; hier alleen het idee.)

Spreiding terugrekenen uit een frequentietabel

Variantie en standaardafwijking (thema 1) werken ook met frequenties — je weegt elke afwijking met hoe vaak hij voorkomt:

$$\bar{y} = \frac{\sum f_i y_i}{n} \quad s_y^2 = \frac{\sum f_i (y_i - \bar{y})^2}{n - 1}$$

Dezelfde gedachte als de blauwe vierkantjes; je telt ze alleen met hun frequentie mee in plaats van één voor één.

In SPSS — klikpad

Data om mee te spelen: [egels.sav](#) — of de [hele zip](#). De five-number summary, de kwartielen én de boxplot mét uitbijters komen in één klap uit *Explore*:

Analyze $\rightarrow$ **Descriptive Statistics** $\rightarrow$ **Explore** $\rightarrow$ variabele naar *Dependent List* $\rightarrow$ bij *Plots...* zet je *Boxplots* aan $\rightarrow$ *Continue* $\rightarrow$ *OK*.

In de output lees je Q_1 , mediaan en Q_3 af bij *Percentiles*; de boxplot tekent de snorharen en zet uitbijters als los puntje erbuiten — precies zoals we ze hier met de hand vonden.

Oefenen

T2.1 — Modus-val

Stel: je hebt een frequentietabel voor je, en de laagste waarde komt er verreweg het vaakst in voor — 37,5 % van de gevallen — terwijl de rest verspreid zit. Een student ziet de tabel, begint meteen te rekenen, en mist de modus. Wat is de modus hier, en waarom is dit een instinker?

Antwoord T2.1

De modus is simpelweg **de laagste waarde** — die met de hoogste frequentie. De instinker: je hoeft niets te berekenen, alleen te kijken welke waarde het vaakst voorkomt. Wie meteen begint te rekenen, zoekt te moeilijk.

T2.2 — Met de hand: kwartielen & uitbijters

Zeven dassen, nachtelijke graaftijd (minuten), op volgorde:

8, 11, 12, 15, 18, 22, 40

Bepaal:

- (a) de mediaan,
- (b) Q_1 en Q_3 ,
- (c) de IQR,
- (d) of de das van 40 minuten een uitbijter is.

Antwoord T2.2

- (a) Mediaan: rangnummer $(7 + 1)/2 = 4 \rightarrow 4\text{e waarde} = 15$.
- (b) $Q_1 = \text{mediaan onderste helft } (8, 11, 12) = 11$; $Q_3 = \text{mediaan bovenste helft } (18, 22, 40) = 22$.
- (c) $\text{IQR} = 22 - 11 = 11$.
- (d) $1,5 \times 11 = 16,5$; bovengrens $= 22 + 16,5 = 38,5$. De das van **40** ligt erboven $\rightarrow$ **uitbijter**. (De verdeling is rechts-scheef: gemiddelde $\approx 18,0 >$ mediaan 15.)

T2.2 in SPSS — kwartielen en boxplot

Data: [dassen.sav](#) — 7 dassen, één kolom graaftijd (8, 11, 12, 15, 18, 22, 40).

Analyze $\rightarrow$ **Descriptive Statistics** $\rightarrow$ **Explore** $\rightarrow$ zet graaftijd bij *Dependent List* $\rightarrow$ bij *Plots...* zet je *Boxplots* aan $\rightarrow$ *Continue* $\rightarrow$ *OK*.

Aflezen: in de tabel *Percentiles* lees je op de rij *Weighted Average* de 25e en 75e percentiel af ($Q_1 = 11$, $Q_3 = 22$) en de mediaan (15) — exact je handwerk. (De rij *Tukey's Hinges* gebruikt een net iets andere positie-formule en geeft hier 11,5 en 20; voor deze opgave is de *Weighted Average*-rij de juiste.) De boxplot zet de das van 40 als los puntje boven de snorhaar — precies de uitbijter die je met de $1,5 \times \text{IQR}$ -regel vond.

T2.3 — Eén uil erbij: positie, waarde, en de brug naar ‘gevoelig’

Vijf uilen, nachtelijke waakzaamheid: 4, 6, 7, 8, 10. (Mediaan én gemiddelde zijn hier allebei 7.)

- (a) Er komt een **zesde** uil bij met waakzaamheid 9. Wat wordt de **positie** (rangnummer) van de mediaan, wat wordt de **waarde**, en wat wordt het gemiddelde?
- (b) Vervang die zesde uil door een **extreme** waakzaamheid van 100. Wat doet dit met de positie en de waarde van de mediaan? En met het gemiddelde?
- (c) Wat leer je hieruit over mediaan versus gemiddelde?

Antwoord T2.3

(a) $n = 6$. Mediaan-positie $= \frac{6+1}{2} = 3,5 \rightarrow$ tussen de 3e en 4e waarde van 4, 6, 7, 8, 9, 10, dus tussen 7 en 8 $\rightarrow$ **waarde** 7,5. Gemiddelde $= \frac{44}{6} \approx 7,33$.

(b) Geordend: 4, 6, 7, 8, 10, 100. De mediaan-positie is nóg steeds 3,5 $\rightarrow$ tussen 7 en 8 $\rightarrow$ **waarde** 7,5 — precies hetzelfde als bij (a)! Het gemiddelde springt naar $\frac{135}{6} = 22,5$.

(c) De **positie** van de mediaan hangt alleen van n af, niet van hoe extreem een waarde is — en de mediaan-**waarde** verschuift nauwelijks (7 $\rightarrow$ 7,5, of er nu een 9 of een 100 bijkomt). Het **gemiddelde** wordt wél meegesleurd door die ene uitschieter (7 $\rightarrow$ 22,5). De mediaan is **robuust**, het gemiddelde **gevoelig**.

Bruggetje naar later: de meeste toetsen die je straks leert — de t -toets en zijn familie — zijn gebouwd op het **gemiddelde**. Dat noemen we *parametrische* methoden, en ze erven die gevoeligheid voor uitschieters. Daarom checken we eerst op uitbijters en scheefheid (thema 2!) vóórdat we zo’n toets vertrouwen.

T2.3 in SPSS — mediaan vs gemiddelde

Data: [uilen.sav](#) — de 5 basis-uilen, één kolom waakzaamheid (4, 6, 7, 8, 10).

Analyze $\rightarrow$ **Descriptive Statistics** $\rightarrow$ **Explore** $\rightarrow$ zet waakzaamheid bij *Dependent List* $\rightarrow$ OK (een boxplot mag, hoeft niet).

Aflezen: in *Descriptives* staan *Mean* = 7,00 én *Median* = 7,00 — bij deze nette symmetrische basis vallen ze samen, precies zoals in de opgave. De zesde uil (en de sprong naar 100) reken je met de hand erbij: je ziet dan dat het *gemiddelde* meebeweegt en de

mediaan nauwelijks. SPSS levert hier het ankerpunt.

Tot slot

Eén getal — het gemiddelde — verbergt een hoop. Pas als je de egels neerlegt langs hun as zie je waar ze écht liggen: of de mediaan netjes in het midden van de box zit (symmetrisch), of dat één ekster met veertig glimmertjes het hele plaatje scheeftrekt. Dat is wat een verdeling je laat zien en een gemiddelde niet: niet *waar het midden ligt*, maar *hoe oneerlijk het eromheen verdeeld is*.

In het volgende deel pakken we één speciale verdeling beet — de normaalverdeling — en gaan we onze ruwe scores eindelijk *standaardiseren*. Want ruw is, zoals je nog vaak gaat horen, ruk.

Werkboek OZP 1 · Thema 2, versie 0.1 (handrekenen & theorie). Doorlopend voorbeeld: de egels.