

Thema 5 · Correlatie

Deel 3 — Samenhang · *bewegen ze samen?*

Inhoudsopgave

Twée variabelen tegelijk	1
Het gevoel: vier kwadranten	3
Covariantie: samen afwijken	4
Ruw is ruk □ de Pearson-correlatie	6
Pas op	7
Oefenen	7
Tot slot	9

Twée variabelen tegelijk

Tot nu toe keken we naar één variabele per keer. Nu twee. De egels worden ouder én langer — en de vraag is: **bewegen die twee samen?** Niet door de tijd, maar in de data: horen hogere leeftijden bij hogere (of juist lagere) lengtes? Als een egel ouder is, is hij dan ook langer? Dat is **samenhang** (correlatie, verband, associatie — allemaal hetzelfde, zie Deel 0).

Ohwoo — we go bivariate

Even feest: vanaf nu kijken we naar **twée** dingen tegelijk. Niet één rijtje getallen meer, maar twee die iets met elkaar te maken kunnen hebben. Dat is een sprong — al is het, eerlijk, nog een bescheiden sprong: twee. De echte knal is *multivariaat*, een hele zwerm variabelen die door elkaar dansen. Dat is voor later; voel 'm eerst met z'n tweeën.


De egels — nu met leeftijd erbij

Bij elke egel meten we nu twee dingen: leeftijd x (maanden) en lengte y (cm).

i	leeftijd x_i	lengte y_i
1	2	11
2	2	20
3	3	14
4	3	23
5	4	20
6	5	26
7	5	29
8	6	17
9	6	20

De lengtes zijn dezelfde negen als in Deel 1: $\bar{y} = 20$, $s_y = \sqrt{31,5} \approx 5,61$. Voor de leeftijd: $\bar{x} = 4$, en (reken na) $s_x = \sqrt{2,5} \approx 1,58$.

Hier is de **wolk** — negen egels, elk een puntje:



Figuur 1: Spreidingsdiagram van de negen egels: leeftijd (maanden) op de horizontale as, lengte (cm) op de verticale as. Elke egel is één punt. Globaal lopen oudere egels iets hoger (langer), maar er zit duidelijk ruis op de wolk.


Kijk er even naar vóór je verder leest: zie je een verband? En valt je iets op — zit er een egel tussen die juist *tegen* de trend in lijkt te gaan?

Het gevoel: vier kwadranten

Teken een verticale lijn op $\bar{x} = 4$ en een horizontale op $\bar{y} = 20$. Dat hakt de wolk in vier kwadranten. Loop nu elke egel langs en vraag twee dingen: scoort hij **hoog of laag op leeftijd**, en **hoog of laag op lengte**?

- **Zelfde kant op** (hoog-hoog óf laag-laag) □ draagt bij aan een **positief** verband.
- **Tegengesteld** (hoog-laag óf laag-hoog) □ draagt bij aan een **negatief** verband.
- **Precies op een gemiddelde** (op leeftijd óf op lengte) □ draagt **niks** bij. Eén afwijking is dan nul, en nul keer wat-dan-ook blijft nul — ook al wijkt die egel op de andere variabele fors af. Eén factor nul, en het hele product is nul.

De meeste egels gaan mee met de trend: jong-en-kort linksonder, oud-en-lang rechtsboven (allebei positief). Maar let op de **dwarssliggers**: een jonge egel die tóch al lang is (linksboven) en een oude egel die kort gebleven is (rechtsonder) — die trekken juist *tegen* het verband in (negatief). En een paar egels liggen precies op de lengte-gemiddelde lijn (lengte 20): die scoren wél gemiddeld op lengte, maar niet op leeftijd. Hun product is nul; ze doen niet mee.



Figuur 2: Dezelfde egels, nu met de gemiddelde-lijnen (stippellijnen op leeftijd 4 en lengte 20) die de wolk in vier kwadranten delen. Blauw = positief product (gaat mee met het verband), oranje = negatief product (dwarsligger), grijs = ligt op een gemiddelde en draagt niets bij. Het teken in elke hoek is het teken van het product van de twee afwijkingen.

Covariantie: samen afwijken

We vangen dat in een getal. Per egel vermenigvuldigen we zijn afwijking op x met zijn afwijking op y — een **kruisproduct**. $\text{Min} \times \text{min} = \text{plus}$, dus *laat je niet vangen door min-min: dat is gewoon plus*. Aan of dat product **plus of min** is — het *teken* — zie je of een egel aan een positief of negatief verband bijdraagt; en een product van nul betekent: doet niet mee.

Elk product is een rechthoekje

Dat kruisproduct $(x_i - \bar{x})(y_i - \bar{y})$ heeft ook een meetkundige kant. Lengte $\times$ breedte is een **oppervlakte** — en hier zijn de twee zijden de twee afwijkingen: hoever deze egel van de gemiddelde leeftijd zit, en hoever van de gemiddelde lengte. Elke egel spant zo zijn eigen **rechthoekje** op.

- Allebei dezelfde kant op (beide plus óf beide min) $\square$ een **positief** rechthoekje.
- De een vóór, de ander tegen $\square$ een **negatief** rechthoekje (er staat een minteken voor).
- Precies op één van de twee gemiddelden $\square$ een **platte** rechthoek, oppervlakte nul (de egel-die-niks-bijdraagt van hierboven).

De covariantie is dan niets anders dan het **gemiddelde van al die rechthoekjes**, hun plus en min netjes meegeteld. Eerst per egel een vlakje, dán pas optellen.

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	product
1	2	11	-2	-9	18
2	2	20	-2	0	0
3	3	14	-1	-6	6
4	3	23	-1	+3	-3
5	4	20	0	0	0
6	5	26	+1	+6	6
7	5	29	+1	+9	9
8	6	17	+2	-3	-6
9	6	20	+2	0	0
som					30

De som van de producten is 30. Deel door $n - 1$ (net als bij de variantie in Deel 1 — we beschrijven een *steekproef*) en je hebt de **covariantie**:

$$s_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n - 1} = \frac{30}{8} = 3,75$$

De $\sum_{i=1}^n$ betekent: tel op over álle egels, van de eerste ($i = 1$) tot de laatste ($i = n = 9$) — dezelfde optel-machine als in thema 1. Omdat we bijna altijd over *alle* egels sommeren,

laten we die grenzen verderop gewoon weg; dan staat er kortweg $\sum$. Eerst expliciet, dan vanzelfsprekend.

Merk op: de twee dwarsliggers (egels 4 en 8, met een negatief product) drukken de som omlaag. Zonder hen zou het verband sterker ogen — maar zo eerlijk is de natuur niet.

Ruw is ruk □ de Pearson-correlatie

Die covariantie van 3,75 — is dat veel? **Ruw is ruk** — al is ‘ruk’ hier nét te streng. Het *téken* (positief) lees je meteen af: leeftijd en lengte gaan samen dezelfde kant op. En het getal zélf bétekent ook iets: het leeft in de **product-eenheid** maand·cm — de gemiddelde rechthoek van hierboven. Wat je er níet aan afziet, is of 3,75 *groot* of *klein* is: dat hangt aan de eenheden. Meet je leeftijd in jaren in plaats van maanden, dan verandert het getal terwijl het verband hetzelfde blijft. Daarom standaardiseren we naar de **Pearson-correlatie** r_{xy} , die altijd netjes tussen -1 en $+1$ loopt. De truc: we delen de **gezamenlijke** beweging (de covariantie) door hoeveel x en y ieder **los** spreiden (s_x en s_y):

$$r_{xy} = \frac{s_{xy}}{s_x \cdot s_y} = \frac{3,75}{\sqrt{2,5} \cdot \sqrt{31,5}} = \frac{3,75}{8,87} \approx 0,42$$

(Hetzelfde als het gemiddelde product van de z-scores, $r_{xy} = \frac{1}{n-1} \sum z_x z_y$ — standaardiseren maakt het vergelijkbaar.) Een r van 0,42: een **matig** positief verband (tegen de 0,5 aan). Vuistregel uit het college: vanaf $\pm 0,2$ zwak, $\pm 0,5$ matig, $\pm 0,8$ sterk. Egels worden dus langer met de leeftijd, maar er is flink wat ruis — precies wat je in de wolk al zag.

Wil je juist weten *hoeveel cm langer per maand* — een echt “zoveel per eenheid” — dan deel je de covariantie niet door béide spreidingen, maar alleen door die van leeftijd. Dan reken je de eenheid maand·cm om naar cm-per-maand: de regressie**helling**. Dat is thema 6. Dezelfde gedeelde beweging, twee keer anders gelezen.

Verklaarde variantie: r^2

Kwadrateer je r , dan krijg je het aandeel **gedeelde variatie**: $r_{xy}^2 = 0,42^2 \approx 0,18$. Oftewel: zo’n 18% van de variatie in lengte hangt samen met de variatie in leeftijd (en dat mag je omdraaien). De overige 82% hangt (nog) niet samen met leeftijd — er speelt veel meer mee dan leeftijd alleen.

In SPSS — klikpad

Data om mee te spelen: [egels.sav](#) — of de [hele zip](#). Met de hand voel je wat er gebeurt; SPSS doet het kruisproduct-rekenwerk voor je. Voor een Pearson-correlatie:

Analyze □ **Correlate** □ **Bivariate** □ zet *leeftijd* en *lengte* naar rechts □ *Pearson* aangevinkt laten □ OK.

In de output-tabel lees je r af op het kruispunt van de twee variabelen (en eronder de bijbehorende p).

Pas op

- **Lineariteit.** r meet alleen *rechte* samenhang. Je kunt door elke wolk een rechte lijn leggen, maar is dat terecht? Een kromme “hema-worst” verstop je niet in een r — teken altijd eerst de scatterplot.
- **Uitbijters** kunnen r flink optillen of platdrukken; één extreem punt doet veel.
- **Schaal maakt niet uit.** Meet je lengte in cm of in meters, r blijft gelijk — hij is gestandaardiseerd.
- **Correlatie $\neq$ causatie.** De egels worden langer *met* de leeftijd, niet noodzakelijk *vanwege* de leeftijd — ze groeien door voedsel, zorg en een beetje liefde. Tijd is geen oorzaak; het is een meeloper. Pas dus op met het woord “invloed”: dat is iets causaals, en daar gaat een correlatie niet over.

Gevoel ontwikkelen

Wil je leren hoe een wolk en een r bij elkaar horen: speel een paar potjes *guess the correlation* (online te vinden). Een strakke, smalle wolk is makkelijk te raden; een ronde wolk ($r \approx 0$) is lastig. Goede oefening vóór je gaat rekenen.

Oefenen

T5.1 — Wie draagt bij, wie werkt tegen?

Kijk naar de productentabel hierboven.

- Welke egel draagt het meest bij aan het positieve verband?
- Twee egels hebben een **negatief** product — welke, en wat is er bijzonder aan die

egels?

(c) Drie egels dragen niks bij — waarom niet?

(d) Wat zou er met r gebeuren als alle egels precies even oud (leeftijd 4) waren?

Antwoord T5.1

(a) Egel 1 (leeftijd 2, lengte 11): de jongste én de kortste, dus van beide gemiddelden ver de “goede” kant op $\square$ product 18.

(b) Egel 4 (leeftijd 3, lengte 23) en egel 8 (leeftijd 6, lengte 17). Het zijn **dwarsliggers**: egel 4 is jong maar tóch al lang, egel 8 is oud maar kort gebleven. Ze gaan tegen de trend in, dus hun product is negatief (-3 en -6) en ze drukken de covariantie omlaag.

(c) Egels 2, 5 en 9 liggen precies op de lengte-gemiddelde lijn (lengte 20): hun afwijking op y is 0, dus het product is 0 — wat hun leeftijd ook is. Ze scoren gemiddeld op lengte en zeggen daarom niets over de samenhang.

(d) Dan is er geen variatie in leeftijd ($x_i - \bar{x} = 0$ voor iedereen), dus alle producten zijn 0 en de covariantie is 0. En dan is ook **de waarde van r** gelijk aan nul — kortweg $r = 0$. Zonder verschil in x kan er geen samenhang zijn — je hebt verschil nodig.

T5.1 in SPSS — controleer de correlatie

Data: `egels.sav` — de negen doorlopende egels, kolommen leeftijd en lengte.

Analyze $\square$ **Correlate** $\square$ **Bivariate** $\square$ zet leeftijd en lengte naar *Variables* $\square$ *Pearson* aangevinkt laten $\square$ *OK*.

Aflezen: op het kruispunt van de twee variabelen staat *Pearson Correlation* = ,423 ($r \approx 0,42$) — exact het getal dat je uit de covariantie (3,75) en de twee spreidingen ($\sqrt{2,5}$ en $\sqrt{31,5}$) met de hand vond. De tabel-opgave (welke egel draagt bij, wie werkt tegen) lees je af uit de kruisproducten; SPSS bevestigt alleen het eindgetal.

T5.2 — Interpreteren

Een onderzoeker vindt tussen schoenmaat en leesvaardigheid bij kinderen een correlatie van $r = 0,70$. Mogen we concluderen dat grotere voeten beter lezen veroorzaken? Wat is hier waarschijnlijk aan de hand?

Antwoord T5.2

Nee — correlatie $\neq$ causatie. Er is vermoedelijk een **derde variabele** die met beide samenhangt: **leeftijd**. Oudere kinderen hebben grotere voeten én lezen beter. De schoen-

maat doet niks; leeftijd loopt mee. (Zo'n meeloper heet ook wel een confounder.)

Tot slot

Alles wat correlatie doet, voelde je al in die vier kwadranten: gaan twee dingen dezelfde kant op, of trekken ze tegen elkaar in? De covariantie telt dat op — gemiddeld rechthoekje — en omdat ruw ruk is delen we 'm door de twee spreidingen, zodat er een r uit komt die altijd tussen -1 en $+1$ ligt. (Al 'bewegen' die egels natuurlijk niks; ze liggen daar gewoon. Wat samen varieert, zijn de **metingen** — deze egel, zó gemeten op leeftijd én lengte. 'Samen bewegen' is het gevoel; 'samen variëren' is wat er precies staat.) Maar let op wat een r je *niet* geeft: richting. Het is een **dubbele pijl** — leeftijd-en-lengte hangen samen, punt. Wie is hier nou de voorspeller? Daar zwijgt de correlatie over. In het volgende thema zetten we er één pijl op, één kant op, en voorspellen we lengte uit leeftijd. Dat is regressie.

Werkboek OZP 1 · Thema 5, versie 0.1 (handrekenen & theorie). Doorlopend voorbeeld: de egels.