

Thema 6 · Regressie

Deel 3 — Samenhang · $DATA = FIT + RESIDU$

Inhoudsopgave

Van dubbele pijl naar enkele pijl	1
Het spelletje: $DATA = FIT + RESIDU$	2
De regressielijn	2
Voorspellen en residuen	4
Hoe goed past het model?	5
Pas op	5
Gestandaardiseerde regressie	6
Oefenen	6
Wat blijft liggen	7
Tot slot	8

Van dubbele pijl naar enkele pijl

In thema 5 vonden we een verband tussen leeftijd en lengte van de egels — een **dubbele** pijl, zonder richting. Nu zetten we er een **enkele** pijl op: we gaan lengte *voorspellen* uit leeftijd. Dat is **regressie**.

Onthoud het woord *regressie* hier als: we brengen een ingewikkelde puntenwolk **terug** tot iets eenvoudigs — een lijn. De variatie in lengte proberen we zo goed mogelijk te *vangen* met de variatie in leeftijd.

Begin met de Y

Mijn vader vertelde verhalen met eindeloze bijzinnen vóór hij bij de clou kwam — pas op het eind wist je waar het heen ging. Doe dat in de statistiek niet. **Begin met de afhankelijke variabele:** wat wil je verklaren? De lengte. En pas dán: waarmee? De leeftijd. “Wij willen lengte voorspellen aan de hand van leeftijd” — meteen helder.

Het spelletje: DATA = FIT + RESIDU

Er komt een egel binnen. Wat is je beste gok voor zijn lengte? Zonder verdere info: het **grote gemiddelde**, 20 cm (Deel 1). Maar nu verklap ik je zijn leeftijd — dan kun je het beter doen, via de **lijn**.

Neem een egel van 5 maanden die 26 cm lang is. We vergelijken eigenlijk twee gokken: de **domme gok** (iedereen 20 cm — het grote gemiddelde) en de **slimme gok** (de lijn). We splitsen zijn afstand tot het grote gemiddelde in twee stukken:

$$\underbrace{(y - \bar{y})}_{\text{totale gok-fout}} = \underbrace{(\hat{y} - \bar{y})}_{\text{wat de lijn verklaart}} + \underbrace{(y - \hat{y})}_{\text{wat overblijft (residu)}}$$

Oftewel: **DATA = FIT + RESIDU**. Voor onze egel (we vinden zo $\hat{y} = 21,5$): de totale gok-fout is $26 - 20 = 6$; daarvan verklaart de lijn $21,5 - 20 = 1,5$; en er blijft $26 - 21,5 = 4,5$ over. En inderdaad: $6 = 1,5 + 4,5$.

Drie stukjes (straks drie kleuren)

Op een spreidingsdiagram teken je deze drie als streepjes: het totale streepje (naar het grote gemiddelde), het stuk dat de lijn ophoest, en het restje van het punt tot de lijn. In de figuur straks geven we ze elk een kleur (blauw = totaal, groen = verklaard, bordeaux = residu). Wie dit spelletje snapt, kan straks regressie én variantieanalyse bijna zonder formules — het is steeds deze opsplitsing.

De regressielijn


De lijn is $\hat{y} = b_0 + b_1x$, met b_0 het **intercept** (startwaarde) en b_1 de **helling** (hoeveel y stijgt per stap in x). Begin met de helling:

$$b_1 = r_{xy} \cdot \frac{s_y}{s_x} = \frac{s_{xy}}{s_x^2} = \frac{3,75}{2,5} = 1,5$$

De helling vraagt eigenlijk: hoeveel **gezamenlijke** beweging is er, vergeleken met hoeveel x in z'n eentje beweegt? (Let op: s_y bóven, s_x onder — een klassieke tentamenva!.) Dan het intercept:

$$b_0 = \bar{y} - b_1 \bar{x} = 20 - 1,5 \cdot 4 = 14$$

Dus: $\hat{y} = 14 + 1,5x$. Twee egels die één maand in leeftijd schelen, verschillen gemiddeld **1,5 cm** in lengte — de oudere is de langere. Let op het werkwoord: egels die ouder *zijn*, niet “een egel die ouder *wordt*”. Onze data zijn een momentopname van negen verschillende egels, geen filmpje van één egel die opgroeit; de helling vergelijkt egels onderling, hij volgt er geen één door de tijd. De lijn start (rekenkundig) op 14 — dat betekent niet dat een pasgeboren egel (leeftijd 0) precies 14 cm is; het is het rekenkundige startpunt, ver buiten het bereik van onze data.



Figuur 1: De regressielijn $\hat{y} = 14 + 1,5 \cdot \text{leeftijd}$ (grijze lijn) door de wolk, met de grijze stippel-
lijn op het grote gemiddelde (lengte 20). Voor een egel van 5 maanden (lengte 26)
is de totale afwijking opgesplitst: blauw = totaal (6), groen = wat de lijn verklaart
(FIT = 1,5), bordeaux = wat overblijft (residu = 4,5). Bij dit matige verband is
het residu veel groter dan de FIT.

Voorspellen en residuen

Vul een leeftijd in en je hebt een voorspelling; trek die van de echte lengte af en je hebt het **residu** $e = y - \hat{y}$ — wat het model mist.

i	leeftijd x_i	lengte y_i	voorspeld $\hat{y}_i = 14 + 1,5 x_i$	residu $e_i = y_i - \hat{y}_i$
1	2	11	17	-6
4	3	23	18,5	+4,5
5	4	20	20	0
7	5	29	21,5	+7,5
8	6	17	23	-6

Een positief residu = de egel is langer dan de lijn voorspelt (punt boven de lijn); negatief = eronder. Egel 4 (jong maar lang) en egel 8 (oud maar kort) — onze dwarsliggers uit thema 5 — hebben de grootste residuen tegen de trend in. (Verwar over- en onderschatting niet: kijk altijd *wat* ten opzichte van *wat* — de echte waarde ten opzichte van de voorspelling.)

In SPSS — klikpad

Data om mee te spelen: [egels.sav](#) — of de [hele zip](#). Met de hand heb je b_0 en b_1 nu zelf gevonden; SPSS hoest dezelfde lijn in twee klikken op.

Analyze → **Regression** → **Linear** → lengte naar *Dependent*, leeftijd naar *Independent(s)* → OK.

Aflezen: het intercept (14) en de helling (1,5) staan in de tabel *Coefficients* onder B; de verklaarde variantie ($R^2 \approx 0,18$) in de tabel *Model Summary*.

Hoe goed past het model?

Spijkerbroek of maatpak?

Een model is een vereenvoudiging van de werkelijkheid — net als een kledingmaat. Een spijkerbroek heeft twee parameters (lengte, breedte, “28/32”) en past *redelijk*. Een maatpak heeft veel meer parameters en past *beter*. Zo ook hier: het allersimpelste model is het grote gemiddelde (één parameter); de regressielijn voegt er één toe (de helling) en past beter. Hoe complexer het model, hoe beter het past — op *déze* data. Maar een maatpak dat perfect om de huidige persoon zit, past de volgende niet per se beter; of een complexer model ook *écht* beter is (en niet alleen toevallig), is een andere vraag (voor later).

De **verklaarde variantie** is $r_{xy}^2 \approx 0,18$ (uit thema 5): de lijn verklaart maar zo’n 18% van de variatie in lengte, 82% blijft in de residuen zitten. Dat zag je in de figuur: voor onze voorbeeld-egel was de FIT (1,5) klein en het residu (4,5) groot. Een matig verband geeft een lijn die *iets* helpt, maar lang niet alles vangt — en dat is eerlijk.

Pas op

- **Niet doortrekken buiten bereik (extrapolatie).** Onze egels zijn 2 tot 6 maanden oud. Worden ze bij 60 maanden 76 cm? Natuurlijk niet — de lijn geldt alleen binnen het

gemeten gebied.

- **Causaliteit.** Net als bij correlatie: de richting (lengte uit leeftijd) is een *gekozen* richting, geen bewijs van oorzaak. We hadden ook leeftijd uit lengte kunnen voorspellen.
- **Negatieve $r \rightarrow$ negatieve helling.** Een consistentiecheck: het teken van b_1 volgt het teken van r_{xy} .

Gestandaardiseerde regressie

Net als b_1 “ruw” is (afhankelijk van eenheden), kun je ook met z -scores werken. Dan voorspel je z_y uit z_x , en het **intercept valt weg** (het wordt 0). Het gestandaardiseerde gewicht is bij enkelvoudige regressie precies de correlatie:

$$\hat{z}_y = r_{xy} \cdot z_x = 0,42 z_x$$

“Ga je 1 standaardafwijking omhoog op leeftijd, dan ga je gemiddeld 0,42 standaardafwijking omhoog op lengte.” Ruw is ruk; gestandaardiseerd is vergelijkbaar.

Oefenen

T6.1 — Voorspellen en residu

Met $\hat{y} = 14 + 1,5x$:

- Wat is de voorspelde lengte van een egel van 5 maanden?
- Een egel van 3 maanden blijkt 20 cm. Wat is zijn residu, en zit hij boven of onder de lijn?

Antwoord T6.1

(a) $\hat{y} = 14 + 1,5 \cdot 5 = 21,5$ cm.

(b) $\hat{y} = 14 + 1,5 \cdot 3 = 18,5$; residu $e = 20 - 18,5 = +1,5$. Positief $\rightarrow$ de egel is langer dan voorspeld $\rightarrow$ hij ligt **boven** de lijn.

T6.1 in SPSS — de lijn terugvinden

Data: `egels.sav` — de negen doorlopende egels, kolommen leeftijd en lengte.

Analyze → **Regression** → **Linear** → lengte naar *Dependent*, leeftijd naar *Independent(s)* → OK.

Aflezen: in de tabel *Coefficients*, kolom *B*, staat het intercept (*Constant*) = 14,00 en de helling (leeftijd) = 1,50. Daarmee voorspel je zelf: een egel van 5 maanden → $14 + 1,5 \cdot 5 = 21,5$ cm — exact je handwerk.

T6.2 — DATA = FIT + RESIDU

Voor de egel van 3 maanden uit T6.1 (lengte 20, $\hat{y} = 18,5$): splits zijn afstand tot het grote gemiddelde (20) in het verklaarde deel en het residu. Klopt DATA = FIT + RESIDU?

Antwoord T6.2

Totale afstand tot $\bar{y}$: $20 - 20 = 0$. Verklaard door de lijn: $\hat{y} - \bar{y} = 18,5 - 20 = -1,5$. Residu: $y - \hat{y} = 20 - 18,5 = +1,5$. Check: $0 = -1,5 + 1,5$. Klopt — de lijn trekt 'm iets naar beneden (jong → korter verwacht), het residu duwt 'm weer terug omhoog.

T6.2 in SPSS — residuen laten opslaan

Data: `egels.sav` — dezelfde negen egels.

Analyze → **Regression** → **Linear** (zelfde opzet als T6.1) → knop *Save...* → onder *Residuals* vink je **Unstandardized** aan → *Continue* → OK. SPSS zet nu een nieuwe kolom RES_1 ($y - \hat{y}$) in je databestand.

Aflezen: voor elke egel zie je het residu — bijv. de twee dwarsliggers (jong-maar-lang, oud-maar-kort) hebben de grootste residuen, net als in de tabel hierboven. *Let op:* de egel uit deze opgave (3 maanden, lengte 20) zit níét in dit groepje — die is hypothetisch. Voor de echte 3-maanders in de data (lengte 14 en 23) lees je residu $-4,5$ en $+4,5$ af; het $+1,5$ uit de opgave reken je zelf met $\hat{y} = 18,5$.

Wat blijft liggen

Hier stopt het voor nu. In een vervolgcursus voeg je méér voorspellers toe (meervoudige regressie) en splits je de hele berg variatie netjes op in *sum of squares* — model versus error. Dat is precies dit DATA = FIT + RESIDU-spelletje, maar dan voor de hele dataset tegelijk.

Tot slot

Het oude model — gok het grote gemiddelde, iedereen 20 — gooien we niet weg; we bouwen erop. Vertel me de leeftijd erbij, en de lijn doet het *nét* iets beter. Niet veel beter, eerlijk gezegd: de FIT was 1,5 en het residu 4,5, de lijn vangt zo'n 18% en mist de rest. Maar dat is geen falen, dat is hoe het is. **DATA = FIT + RESIDU** — wat je modelleert plus wat je laat liggen, en dat tweede stuk lieg je nooit weg. Onthoud dit spelletje goed, want de zware modellen die nog komen zijn allemaal ditzelfde, alleen met meer streepjes.

Werkboek OZP 1 · Thema 6, versie 0.1 (handrekenen & theorie). Doorlopend voorbeeld: de egels.