

# Thema 11 · Chi-kwadraat & Simpson

## Deel 6 — Categorieën · aantallen tellen

### Inhoudsopgave

|                                              |    |
|----------------------------------------------|----|
| Van getallen naar categorieën                | 1  |
| Chi-kwadraat goodness-of-fit                 | 2  |
| Chi-kwadraat onafhankelijkheid (kruistabel)  | 4  |
| De val van Simpson — een verband dat omkeert | 9  |
| Oefenen                                      | 10 |
| Tot slot                                     | 12 |

### Van getallen naar categorieën

Tot nu toe verdiende elke meting een getal op een schaal: pienterheid, lengte, leeftijd. Maar veel waarnemingen zijn **categorisch**: bruin / grijs / zwart, geslaagd / gezakt, links / midden / rechts. Daar begin je niet met gemiddelden, maar met **tellen**. En daar past één toetsfamilie: de **chi-kwadraat**.

Twee smaken:

1. **Goodness-of-fit** — past mijn ene categorische variabele bij een verwachte verdeling? (Eén rij.)
2. **Onafhankelijkheid** — hangen twee categorische variabelen samen? (Een kruistabel.)

Beide draaien om hetzelfde recept: vergelijk **geobserveerd** met **verwacht** onder  $H_0$ , en tel de gestandaardiseerde afwijkingen op. Het is opnieuw **DATA = FIT + RESIDU**: wat zien we ( $O$ ), wat verwacht het model ( $E$ ), en hoeveel blijft er over ( $O - E$ )?

## Chi-kwadraat goodness-of-fit

### De egels — drie pelskleuren


Onder egels zien we drie pelskleuren: bruin, grijs en zwart. De biologen vermoeden dat ze in de natuur gelijk verdeeld zijn ( $1/3$  elk). Wij vangen er 90 en zien: **40 bruin, 30 grijs, 20 zwart**. Klopt de gelijke verdeling, of niet?

Onder  $H_0$  (gelijke verdeling) verwachten we  $90/3 = 30$  egels per kleur. Bereken voor elke categorie het verschil en kwadrateer dat (we **kwadrateren** zodat plus- en min-afwijkingen elkaar niet wegvlakken — net als bij de blauwe vierkantjes van de variantie in thema 1), gedeeld door  $E$ :


| kleur | geobs. $O$ | verw. $E$ | $O - E$ | $\frac{O - E}{\sqrt{E}}$ | $\frac{(O - E)^2}{E}$             |
|-------|------------|-----------|---------|--------------------------|-----------------------------------|
| bruin | 40         | 30        | +10     | <b>+1,83</b>             | 3,33                              |
| grijs | 30         | 30        | 0       | 0                        | 0                                 |
| zwart | 20         | 30        | -10     | <b>-1,83</b>             | 3,33                              |
|       |            |           |         |                          | <b><math>\chi^2 = 6,67</math></b> |

Vrijheidsgraden:  $df = k - 1 = 3 - 1 = 2$  — de  $df$  volgt uit het **aantal categorieën** ( $k = 3$  kleuren), niet uit het aantal egels. Kritieke waarde  $\chi^2_{0.05, df=2} = 5,99$  (uit de tabel). Onze 6,67 is groter □ **verwerp de nulhypothese**: de pelskleuren zijn **niet** gelijk verdeeld.

Maar  $\chi^2$  zelf zegt alleen *dát* het patroon afwijkt — de **cellen** vertellen *waar*. Daarvoor lees je de **ruwe celresiduen**  $\frac{O - E}{\sqrt{E}}$  (de vierde kolom): bruin zit **+1,83** boven verwachting, zwart **-1,83** eronder, grijs precies goed. Een residu voorbij ongeveer  $\pm 2$  is een opvallende cel — al is dat een *ruwe* vuistregel; hoe je een cel écht standaardiseert (en waarom  $\sqrt{E}$  daarvoor te grof is) zie je zo bij de kruistabel. En kwadrateer je zo'n residu, dan krijg je exact die cel z'n **bijdrage aan  $\chi^2$**  ( $1,83^2 \approx 3,33$ ) — samen weer 6,67. Zo zie je niet alleen of het afwijkt, maar welke kleur het verschil maakt.



Figuur 1: Geobserveerd (blauw) vs verwacht onder gelijke verdeling (grijze stippellijn op 30). Bruin zit boven het verwachte, zwart eronder; samen levert dat een chi-kwadraat van 6,67.



Figuur 2: De chi-kwadraat-engine gaat maar één kant op:  $\chi^2 \rightarrow p$ , en je leest altijd de **rechterstaart**. Je telt de cel-bijdragen  $(O - E)^2/E$  op tot één  $\chi^2$ , en zoekt de kans op “dit of nog schever” in de  $\chi^2$ -tabel (bij  $df = k - 1$ ). Groot  $\chi^2$   $\square$  klein staartje  $\square$  verwerpen. En let op:  $\chi^2$  ként geen richting — een cel té hoog of té laag telt allebei mee, want alles wordt gekwadrateerd. Die twee kanten zitten dus al in dat ene kwadraat: daarom één rechterstaart en **nooit Pippi** (de  $\times 2$  is al voor je gedaan).

### Chi-kwadraat-toetsingsgrootheid

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

- $\chi^2$  — de toetsingsgrootheid: hoe sterk het geobserveerde van het verwachte afwijkt
- $O$  — het **geobserveerde** aantal in een cel (wat je telt)
- $E$  — het **verwachte** aantal in die cel onder  $H_0$
- $(O - E)^2$  — de afwijking per cel, gekwadrateerd (zodat plus en min niet wegval-  
len)
- delen door  $E$  — zodat een grote cel niet vanzelf zwaarder meetelt
- $\sum$  — tel op over **alle** cellen

**Vrijheidsgraden** — uit het aantal categorieën: goodness-of-fit  $df = k - 1$  ( $k$  = aantal categorieën); kruistabel  $df = (r - 1)(c - 1)$  ( $r$  rijen,  $c$  kolommen).

**Wanneer:** categorische data — geobserveerde tegen verwachte aantallen onder  $H_0$ .

## Chi-kwadraat onafhankelijkheid (kruistabel)

Roken  $\times$  geslacht — een vermoeden dat iedereen al heeft

We vragen 400 mensen of ze roken, en noteren hun geslacht. Hier heeft iedereen al een onderbuikgevoel bij: roken mannen vaker? Vraag: hangt roken samen met geslacht?

|                     | rookt | rookt niet | rij-totaal |
|---------------------|-------|------------|------------|
| mannen              | 40    | 160        | 200        |
| vrouwen             | 20    | 180        | 200        |
| <b>kolom-totaal</b> | 60    | 340        | 400        |

**Voel eerst wat “verwacht” betekent.** In het algemeen rookt 60 van de 400 — **15%** (iedereen die binnen kan wandelen én rookt). Stel nu dat roken en geslacht **onafhankelijk** zijn, dat het één niks met het ander te maken heeft: dan zou je verwachten dat in elke groep gewoon diezelfde 15% rookt. Je past die kans niet aan omdat er toevallig een man of een vrouw komt binnenwandelen. 200 mannen  $\square$  je verwacht  $0,15 \cdot 200 = 30$  rokers. Maar er roken er **40**.

Méér dan verwacht — precies wat je onderbuik al fluisterde. En bij de vrouwen andersom: verwacht 30, geobserveerd 20, minder. Juist in dat gat tussen *verwacht* en *geobserveerd* zit het verhaal — en daar mag je van schrikken. Die verwachte aantallen zijn het meest informatief: heb je ze eenmaal, dan vertelt de rest zich vanzelf.

Het rekenen zelf is een **beweging**, geen formule om te stampen. Voor een cel: kijk naar zijn **rijtotaal** (opzij) en zijn **kolomtotaal** (omlaag), vermenigvuldig die twee, en deel door  $N$ .  
*Cel*  $\square$  *rij*  $\square$  *kolom*  $\square$  *delen door*  $N$ .

- $E(\text{man, rookt}) = \frac{200 \cdot 60}{400} = 30$  — precies die 15% van zojuist
- $E(\text{vrouw, rookt}) = \frac{200 \cdot 60}{400} = 30$
- $E(\text{man, niet}) = \frac{200 \cdot 340}{400} = 170$ ,  $E(\text{vrouw, niet}) = 170$

Verwachte celwaarde (onder onafhankelijkheid)

$$E = \frac{\text{rijtotaal} \times \text{kolomtotaal}}{N}$$

- $E$  — het **verwachte** aantal in een cel áls de twee variabelen onafhankelijk zijn
- rijtotaal — het totaal van de rij waarin de cel ligt (kijk opzij)
- kolomtotaal — het totaal van de kolom waarin de cel ligt (kijk omlaag)
- $N$  — het totale aantal waarnemingen
- de **beweging**: cel  $\square$  rijtotaal  $\square$  kolomtotaal  $\square$  delen door  $N$

**Wanneer:** bij een kruistabel — je hebt  $E$  per cel nodig vóór je  $\chi^2$  kunt berekenen.

Vervolgens  $\sum (O - E)^2 / E$  over alle vier de cellen:

$$\begin{aligned} \chi^2 &= \frac{(40 - 30)^2}{30} + \frac{(20 - 30)^2}{30} + \frac{(160 - 170)^2}{170} + \frac{(180 - 170)^2}{170} \\ &= 3,33 + 3,33 + 0,59 + 0,59 = 7,84 \end{aligned}$$

Ook hier volgt  $df$  uit het **aantal categorieën** — nu in twee richtingen: het aantal **rijen** en het aantal **kolommen**. Voor een kruistabel met  $r$  rijen en  $c$  kolommen:  $df = (r - 1)(c - 1)$ . Hier een  $2 \times 2$ -tabel, dus  $df = 1 \cdot 1 = 1$ . (Intuïtie: liggen de rij- en kolomtotalen vast, dan kun je nog  $(r - 1)(c - 1)$  cellen vrij invullen; de rest volgt dwingend.) Kritieke waarde  $\chi^2_{0.05, df=1} = 3,84$ . Onze 7,84 is groter  $\square$  **verwerp de nulhypothese**: roken hangt samen met

geslacht — mannen roken vaker dan je onder onafhankelijkheid zou verwachten, precies wat iedereen al dacht.

Welke cel drijft dat? Weer de **ruwe celresiduen**  $\frac{O - E}{\sqrt{E}}$ : de twee **rookt**-cellen springen eruit ( $\pm 1,83$ :  $\frac{40-30}{\sqrt{30}} = +1,83$  bij mannen,  $-1,83$  bij vrouwen), terwijl de niet-rokers veel kleiner zijn ( $\pm 0,77$ ). Daar — bij wie wél rookt — wijkt de werkelijkheid het sterkst van onafhankelijkheid af.

Ruw is ruk — ook bij residuen (waarom  $\sqrt{E}$  te kort door de bocht is)

Die  $\frac{O - E}{\sqrt{E}}$  is een **ruwe** residu. Mooi, want z'n kwadraat is precies de celbijdrage aan  $\chi^2$  — maar hij heeft één vervelende eigenschap: zijn standaarddeviatie is **niet** 1. En je weet het inmiddels: ruw is ruk. Wil je 'm tegen  $\pm 1,96$  leggen (de  $z$  uit thema 3), dan moet hij éérst écht gestandaardiseerd worden.

Waarom is  $\sqrt{E}$  te groot?  $\sqrt{E}$  is de spreiding van een **vrije** cel — een telling die los mag fluctueren (variantie = gemiddelde =  $E$ , zoals bij een vrij oplopende telling). Maar jouw cel is niet vrij. Hij hangt vast aan zijn **rijtotaal** en zijn **kolomtotaal**: die liggen vast, en dat bindt de cel. Een gebonden cel kan minder ver afdwalen dan een vrije, dus zijn echte spreiding is *kleiner* dan  $\sqrt{E}$ . Deel je alleen door  $\sqrt{E}$ , dan deel je door te véél — je residu wordt te klein — je bent te voorzichtig en mist échte uitschieters.

De **gestandaardiseerde celresidu** corrigeert dat: hij deelt óók door de bindingsfactor  $\sqrt{(1 - \text{rij}/n)(1 - \text{kol}/n)}$ . Pas dié mag je als een gewone  $z$  aflezen.

**Op de rokers.** De man-rookt-cel: ruw  $\frac{40 - 30}{\sqrt{30}} = 1,83$  — netjes ónder  $\pm 2$ , je zou 'm bijna laten lopen. Maar de bindingsfactor is  $\sqrt{(1 - \frac{200}{400})(1 - \frac{60}{400})} = \sqrt{0,5 \cdot 0,85} = 0,65$ , en dus:

$$\text{gestd. celresidu} = \frac{1,83}{0,65} = 2,80.$$

Voorbij  $\pm 2$  — wél een uitschieter. De ruwe versie had je 'm bijna laten missen.

En de cirkel sluit: weet je nog dat bij een  $2 \times 2$ -tabel  $\chi^2 = z^2$ ? Dáár is die  $z$ .  $\sqrt{7,84} = 2,80$ , en  $2,80^2 = 7,84$ . Rond. De ruwe 1,83 was alleen de cel z'n *hapje* van  $\chi^2$ ; de gestandaardiseerde 2,80 ís de hele  $z$ .

Gestandaardiseerde celresidu (adjusted standardized residual)

$$\text{gestd. celresidu} = \frac{O - E}{\sqrt{E \left(1 - \frac{\text{rijtotaal}}{n}\right) \left(1 - \frac{\text{kolomtotaal}}{n}\right)}}$$

- $O$  — het **geobserveerde** aantal in de cel
- $E$  — het **verwachte** aantal in die cel onder  $H_0$  (onafhankelijkheid)
- rijtotaal, kolomtotaal — de totalen van de rij en de kolom waarin de cel ligt
- $n$  — het totale aantal waarnemingen
- de noemer — de **echte** standaarddeviatie van  $O - E$ :  $\sqrt{E}$ , gecorrigeerd voor de binding aan de marges (altijd kleiner dan  $\sqrt{E}$ , dus de residu wordt *groter*)

**Wanneer:** als je een afzonderlijke cel wilt toetsen — voorbij  $\pm 1,96$  is die cel significant (tweezijdig,  $\alpha = .05$ ). Het *ruwe*  $\frac{O - E}{\sqrt{E}}$  gebruik je alleen voor de celbijdrage aan  $\chi^2$ , niet om tegen  $z$  te leggen.


Eén waarschuwing:  $\chi^2$  wordt vanzelf groter bij een grotere steekproef. Een hoge  $\chi^2$  betekent dus *significant*, niet automatisch *een sterk verband* — maten voor de **sterkte** (zoals Cramér's  $V$ ) leer je later.

#### Is chi-kwadraat één- of tweezijdig? (richtingloos)

Strikvraag.  $\chi^2$  kent **geen richting**: door het kwadrateren telt elke afwijking — een cel té hoog of té laag — even hard mee. De toets vraagt niet “hoger of lager?” maar “wijkt het af, hoe dan ook?”. In die zin is  $\chi^2$  **stiekem tweezijdig** (bij meer dan twee categorieën eigenlijk: *alle* kanten tegelijk).

Maar juist omdat beide kanten al in dat kwadraat zitten, lees je **één** staart (de rechter) en doe je **nooit  $\times 2$**  — de “keer 2” van een tweezijdige  $z$ -toets is hier al gedaan door het kwadrateren.

Mooiste bewijs: bij deze  $2 \times 2$ -tabel ( $df = 1$ ) is het *létterlijk* tweezijdig. Daar geldt  $\chi^2 = z^2$ , en de rechterstaart-kans van  $\chi^2$  is exact de **tweezijdige**  $p$  van die  $z$ . De  $\times 2$  zit er dus echt al in.



Figuur 3: Aantal rokers per geslacht (blauw) tegen het verwachte aantal onder onafhankelijkheid (grijze stippellijn op 30). Mannen zitten erboven (40), vrouwen eronder (20) — juist dát gat tussen verwacht en geobserveerd pikt de chi-kwadraat op.

#### Het stappenplan voor een chi-kwadraat

1. OV: hangen twee variabelen samen? (Of, bij GOF: past de verdeling van één variabele bij wat we verwachten?)
2.  $H_0$ : onafhankelijkheid (of: past bij verwachte verdeling).  $H_1$ : hangt samen (of: wijkt af).
3. Toetskeuze: chi-kwadraat (onafhankelijkheid of goodness-of-fit).
4. Onder  $H_0$ : bereken de verwachte aantallen per cel.
5. Toetsingsgrootte:  $\chi^2 = \sum (O - E)^2 / E$ .
6.  $df = (r - 1)(c - 1)$  voor kruistabel ( $r$  rijen,  $c$  kolommen);  $k - 1$  voor goodness-of-fit ( $k$  categorieën).
7. Vergelijk met  $\chi^2_{\alpha, df}$  in de tabel.
8. Conclusie: *de samenhang tussen X en Y* — zeg wélk verband (richting en welke cellen beoordeel je uit de tabel en de residuen, niet uit  $\chi^2$  zelf).

#### In SPSS — klikpad

**Data om mee te spelen:** [roken\\_geslacht.sav](#) en [egel\\_pelskleur.sav](#) — of de [hele zip](#). Met de hand snap je nu wat er gebeurt; in SPSS doe je dezelfde toets met twee categorische variabelen.

Analyze ☐ Descriptive Statistics ☐ Crosstabs ☐ één variabele naar Row(s), de andere naar Column(s) ☐ Statistics... ☐ Chi-square aanvinken ☐ Continue ☐ OK.

Je leest de toets af in de regel *Pearson Chi-Square*: de waarde van  $\chi^2$ ,  $df$  en de bijbehorende kans (*Asymptotic Significance*).

## De val van Simpson — een verband dat omkeert

Alles wat we sinds correlatie (thema 5) doen heeft één gevaar: een globaal verband kan subgroepen verbergen. Een kruistabel laat het *globale* plaatje zien. Maar soms verbergt dat plaatje een **omgekeerd** verband dat binnen subgroepen leeft. Dat is **Simpson's paradox**, en je moet 'm kennen — anders trek je serieus de verkeerde conclusie.

Twee opleidingen, één raar plaatje


Een universiteit kijkt naar de slaagpercentages van jongens en meisjes bij twee opleidingen.

**Opleiding A (makkelijk):** jongens  $480/800 = 60\%$  geslaagd; meisjes  $140/200 = 70\%$  geslaagd. ☐ meisjes scoren beter.

**Opleiding B (moeilijk):** jongens  $40/200 = 20\%$  geslaagd; meisjes  $200/800 = 25\%$  geslaagd. ☐ meisjes scoren beter.

**Totaal:** jongens  $520/1000 = 52\%$ ; meisjes  $340/1000 = 34\%$ . ☐ jongens scoren beter  
?!

Binnen elke opleiding doen meisjes het beter; maar in het totaal lijken jongens beter. Hoe kan dat? **Doordat de groepen zich anders verdelen over de opleidingen.** Veel meisjes deden de moeilijke opleiding (waar iederéén slechter scoort), en veel jongens de makkelijke. Dat trekt het meisjes-gemiddelde naar beneden en het jongens-gemiddelde omhoog.



Figuur 4: Simpson-paradox visueel. Per opleiding (A makkelijk, B moeilijk) scoren meisjes hoger dan jongens. Maar in het totaal scoren jongens hoger — omdat ze relatief veel in de makkelijke opleiding zaten en meisjes in de moeilijke. De aggregatie verbergt de échte richting.

#### Les uit Simpson

Een **derde variabele** (hier: opleiding) die met beide andere samenhangt, kan een verband doen kantelen. *Aggregeer dus nooit zonder na te denken*: kijk altijd binnen relevante subgroepen. Dit is ook precies wat een covariaat doet in latere analyses — controleren voor zo'n meelopende variabele.

## Oefenen

### T11.1 — Chi-kwadraat met de hand

Honderd egels worden in drie hokken gezet (links / midden / rechts). Onder  $H_0$  verwachten we gelijke voorkeur. Telling: links 25, midden 50, rechts 25.

- Bereken  $\chi^2$ .
- Met  $df = 2$  en  $\chi^2_{0.05} = 5,99$  — verwerpen?

### Antwoord T11.1

(a)  $E = 100/3 \approx 33,33$  per hok. Per hok  $(O - E)^2/E$ :

- links:  $(25 - 33,33)^2/33,33 = 2,08$
- midden:  $(50 - 33,33)^2/33,33 = 8,33$
- rechts: idem links = 2,08

$$\chi^2 = 2,08 + 8,33 + 2,08 = 12,5.$$

(b)  $12,5 > 5,99$  → verwerpen. De egels hebben een sterke voorkeur voor het middelste hok.

### T11.1 in SPSS — goodness-of-fit

**Data:** [egel\\_hok.sav](#) — 100 egels, één kolom hok (1 = links, 2 = midden, 3 = rechts; links 25, midden 50, rechts 25).

Dit is een **goodness-of-fit** (één variabele tegen een verwachte verdeling), dus *niet* Cross-tabs maar: **Analyze** → **Nonparametric Tests** → **Legacy Dialogs** → **Chi-square** → zet hok bij *Test Variable List* → onder *Expected Values* staat *All categories equal* (de gelijke verdeling uit  $H_0$ ) → OK.

Aflezen: *Chi-Square* = 12,50, *df* = 2, *Asymp. Sig.* = ,002 — exact je handwerk ( $\chi^2 = 12,5$ ), en ruim onder .05, dus verwerpen. (De data staat hier al uitgekapt — 1 rij per egel — zodat je niets hoeft te wegen. Had je een teltabel met 3 rijen, dan eerst **Data** → **Weight Cases** op de aantallen-kolom.)

### T11.2 — Simpson herkennen

Een schoolinspecteur bekijkt twee scholen op één-jaars-doorstroom. School X: 80%. School Y: 65%. School X lijkt beter. Maar binnen elke leerlingcategorie (laag / hoog vooropleidingsniveau) doet School Y het juist iets *beter*. Hoe kan dat?

### Antwoord T11.2

School X heeft waarschijnlijk veel meer leerlingen met een hoog vooropleidingsniveau (die sowieso vaker doorstromen, op elke school). Het aggregaatcijfer reflecteert dus vooral de samenstelling van de leerlingen, niet de kwaliteit van de school. Net als bij Simpson: een meelopende derde variabele (vooropleiding) verklaart het schijnverschil. Wie scholen eerlijk wil vergelijken, vergelijkt binnen vooropleidingsniveau — niet over de hoofden heen.

## Tot slot

Geen gemiddelden meer, gewoon tellen — maar onder de motorkap is er niks veranderd. Je zet wat je ziet ( $O$ ) naast wat het model verwacht ( $E$ ), en in dat gat ertussen zit het hele verhaal. Te groot een gat, gekwadraterd en opgeteld, en je gooit “het is toeval” overboord. De fiets in de bakker, nu in een kruistabel. En onthoud dat ene:  $\chi^2$  kent geen richting, alles wordt gekwadraterd, dus nooit Pippi.

En dan Simpson, helemaal aan het eind, als een waarschuwing die je nooit meer kwijtraakt: aggregeren is een vorm van vergeten. De subgroepen zwijgen niet — je hoort ze alleen niet meer.

---

*Werkboek OZP 1 · Thema 11, versie 0.1 (handrekenen & theorie). Doorlopend voorbeeld: de egels (+ alledaagse voorbeelden: roken, school).*